



ĐẠI HỌC
BÁCH KHOA HÀ NỘI
HANOI UNIVERSITY
OF SCIENCE AND TECHNOLOGY

Dự đoán tổn thương thận cấp (AKI) ở bệnh nhân nhiễm toan ceton (DKA) với Random Forest

Giảng viên hướng dẫn: TS. Nguyễn Hồng Quang
Sinh viên thực hiện: Đỗ Thành Đạt - 20261103M

ONE LOVE. ONE FUTURE.

1. Bối cảnh và bài toán
2. Kiến trúc tổng thể
3. Tiền xử lý dữ liệu
4. Huấn luyện mô hình
5. Kết quả và đánh giá
6. Kết luận và định hướng



Bối cảnh lâm sàng

Nhiễm toan ceton (DKA) là cấp cứu nội tiết – chuyển hoá thường gặp. Biến chứng **tổn thương thận cấp (AKI)** làm tăng tử vong, nguy cơ bệnh thận mạn và chi phí điều trị. Dự đoán sớm ngay khi nhập ICU giúp bác sĩ phân tầng nguy cơ và can thiệp kịp thời.

BÀI TOÁN

Phân loại nhị phân

Đầu vào: thông tin bệnh nhân DKA trong 24 giờ đầu ICU

Đầu ra: có phát triển AKI trong vòng 1 tuần hay không?

Nhãn: akdPositive (boolean), theo tiêu chuẩn KDIGO

Ba thách thức chính



Mất cân bằng lớp

Chỉ 38,9% ca dương tính → độ chính xác (accuracy) kém tin cậy, cần ROC-AUC.



Chuỗi thời gian


Đặc trưng động dài ngắn khác nhau, phải tổng hợp về biểu diễn cố định mà không mất tín hiệu cảnh báo bệnh.



Nguy cơ quá khớp

Tập dữ liệu nhỏ (970 mẫu) dễ overfit → cần chính quy hoá & kiểm định chéo.

KIẾN TRÚC TỔNG THỂ



Luồng huấn luyện:

- Train.json qua Module A - Tiền xử lý dữ liệu (làm phẳng min/mean/max, KNN, mã hoá, chuẩn hoá) tạo ra tập dữ liệu train đã xử lý với 970 bệnh nhân và 77 trường dữ liệu.
- Module B tách 80/20 cho dữ liệu train và validation, sử dụng GridSearchCV để thử nghiệm chọn cấu hình tốt nhất, rồi huấn luyện lại trên toàn bộ 970 mẫu và tinh chỉnh ngưỡng để cho ra mô hình cuối cùng.

Luồng dự đoán:

- Test.json được tiền xử lý theo Module A, sau đó đưa vào mô hình cuối cùng để dự đoán xác suất tổn thương thận cấp, cùng ngưỡng cho ra nhãn AKI, xuất ra file kết quả.

Tập dữ liệu — MIMIC-IV

Nguồn: trích xuất từ **MIMIC-IV** (Johnson và cộng sự, 2023) theo nghiên cứu Fan và cộng sự (2023). Nhãn **akdPositive** cho biết bệnh nhân có phát triển AKI hay không, theo tiêu chuẩn KDIGO.

970

bản ghi train

243

bản ghi test

38,9%

dương tính



Định dạng JSON • mỗi bệnh nhân có **37 trường đo** (measures), chia hai nhóm tĩnh / động.

Tổng quan các tập dữ liệu

Tập	Số bản ghi	Có nhãn?	Tỉ lệ dương tính
train.json	970	Có	38,9%
test.json	243	Không	—

LƯU Ý PHÂN TÍCH

Thách thức:

dữ liệu nhỏ (970 mẫu) + mất cân bằng + chuỗi thời gian độ dài thay đổi.



Đặc trưng tĩnh

20 trường

Mỗi trường một giá trị duy nhất

Nhân khẩu học — age, gender, race

Loại bệnh — dka_type, liver_disease

Điểm độ nặng — oasis, saps2, sofa

Chức năng thận — egfr, preiculos

Bệnh nền (cờ 0/1) — tăng huyết áp, suy tim, ung thư, biến chứng mạch máu, giai đoạn CKD...



Đặc trưng động

17 trường

Chuỗi thời gian {thời điểm : giá trị} trong 24h đầu ICU

Sinh hiệu (lấy mẫu dày) — hr, rr, sbp, dbp, gcs

Xét nghiệm (lấy mẫu thưa) — bun, scr, ag, bg, bicarbonate, phosphate, calcium, weight, plt, hb, wbc

Vấn đề cần giải quyết

Mỗi chuỗi có độ dài khác nhau (hàng chục đến hàng trăm điểm). Cần tổng hợp thành một biểu diễn cố định để đưa vào mô hình — đây chính là trọng tâm của khâu tiền xử lý.

MODULE A - Tiền xử lý dữ liệu

1

Làm phẳng (flatten)

Mỗi bệnh nhân thành một dòng. Đặc trưng tĩnh giữ nguyên; mỗi đặc trưng động $\rightarrow$ 3 thống kê min/mean/max ($17 \times 3 = 51$ cột).

2

Điền 0 cho cờ bệnh nền vắng

Thông tin bệnh nền và ckd_stage chỉ ghi nhận khi có bệnh $\rightarrow$ "vắng mặt" là khuyết cấu trúc (không mắc), không phải dữ liệu thiếu.

3

Loại biến khuyết > 20% + KNN

Trên dữ liệu này không biến nào vượt ngưỡng (tối đa $\approx 5,9\%$). Điền giá trị thiếu bằng KNNImputer ($k = 5$).

4

Mã hoá & chuẩn hoá

gender, liver_disease, race $\rightarrow$ mã hóa và sử dụng one-hot. Chuẩn hoá cột số bằng StandardScaler

5

Lưu thành joblib để tái sử dụng với tập Test

Imputer + scaler + danh sách cột lưu vào preprocessor.joblib



Đầu ra

970 × 77

ma trận đặc trưng số
đã chuẩn hoá

+ preprocessor.joblib

bộ biến đổi tái sử dụng, bảo
đảm so sánh công bằng & tái
lập kết quả.



Vì sao giữ cực trị?


Các giá trị cực trị mang tín hiệu lâm sàng: **đỉnh creatinine / BUN**, hay **huyết áp thấp nhất**. Lấy trung bình sẽ làm phẳng và che giấu các tín hiệu này.

BẢNG CHỨNG ĐỊNH LƯỢNG

Tương quan của huyết áp tâm thu (sbp) với nhãn AKI

Cùng một biến, ba thống kê cho ba quan hệ hoàn toàn khác nhau — giá trị trung bình che giấu gần như hoàn toàn quan hệ mà min / max bộc lộ.

Tương quan sbp ↔ nhãn theo từng thống kê



MODULE B - Huấn luyện mô hình Random Forest

Tập	Số bệnh nhân	% dương tính	Mục đích
Huấn luyện (Train)	776	38,9%	Huấn luyện & kiểm định chéo
Kiểm thử nội bộ	194	38,7%	Đánh giá hiệu năng
Kiểm thử (Test)	243 → 222*	không nhãn	Dự đoán & nộp kết quả
Huấn luyện lại (Refit)	970	38,9%	Khớp mô hình cuối

* Mỗi *subjectId* chỉ giữ một bản ghi (bản ghi đầu tiên) → 243 bản ghi rút còn 222 bệnh nhân khi xuất kết quả.



Nguyên tắc tách

Tách 20% phân tầng

từ dữ liệu huấn luyện làm validation, giữ nguyên tỉ lệ dương tính.

Chống rò rỉ dữ liệu

bộ tiền xử lý chỉ fit trên train, chỉ transform trên validation/test.

Huấn luyện lại trên toàn bộ 970 mẫu

sau khi chọn cấu hình tốt nhất, để tận dụng tối đa dữ liệu trước khi dự đoán test.

MODULE B - Huấn luyện mô hình Random Forest



Bagging

Mỗi cây huấn luyện trên một mẫu bootstrap (lấy có hoàn lại) → tạo sự đa dạng giữa các cây.



Feature subsampling

Tại mỗi nút chỉ xét max_features ngẫu nhiên ($\log_2 77 \approx 6$) → khử tương quan giữa các cây.



Tiêu chí chia + cân bằng lớp

Độ vẩn Gini chọn phép chia tốt nhất; `class_weight='balanced'` phạt nặng lỗi lớp thiểu số.



Dự đoán bằng trung bình

$P(y=1 | x)$ = trung bình xác suất trên toàn bộ cây → giảm phương sai so với một cây đơn.

Vì sao Random Forest?

Ổn định “out-of-the-box”, ít nhạy siêu tham số

Phi tuyến & bắt được tương tác đặc trưng

Diễn giải được qua feature importance (mức giảm Gini)

Mô hình nền mạnh làm mốc so sánh công bằng

MODULE B - Huấn luyện mô hình Random Forest

1.080

tổ hợp tham số

5.400

lần khớp (×5-fold)

ROC-AUC

độ đo chọn mô hình

~45 phút

trên 6 nhân CPU

Không gian tìm kiếm siêu tham số ($4 \times 5 \times 3 \times 3 \times 3 \times 2 = 1.080$ tổ hợp)

Siêu tham số	Giá trị thử	Vai trò
n_estimators	200, 300, 500 , 800	Số cây — nhiều hơn → ổn định hơn
max_depth	None , 5, 10, 20, 30	Kiểm soát quá khớp chính
min_samples_split	2 , 5, 10	Chính quy hoá
min_samples_leaf	1, 2 , 4	Làm mượt / chống quá khớp
max_features	'sqrt', ' log2 ', 0.5	Mức khử tương quan giữa các cây
bootstrap	True , False	Bật / tắt bagging



Quy trình

StratifiedKFold(5)

kiểm định chéo phân tầng,
chọn theo ROC-AUC.

class_weight='balanced'

giữ cố định để cô lập ảnh
hưởng siêu tham số cấu trúc.

random_state = 42

bộ chia cố định → tái lập
được hoàn toàn.

rf_grid_search_all.csv

ghi lại toàn bộ tổ hợp & điểm
CV (sắp theo hạng).

MODULE B - Huấn luyện mô hình Random Forest

Mô hình tinh chỉnh trên tập kiểm thử nội bộ (194 bệnh nhân)

Ngưỡng	AUC	Accuracy	Sensitivity	Specificity	F1
0,50 (mặc định)	0,807	0,758	0,667	0,815	0,680
0,47 (max-F1)	0,807	0,763	0,707	0,798	0,697
0,33 (lâm sàng)	0,807	0,670	0,853	0,555	0,667

Ngưỡng 0,47

Cân bằng F1

Độ nhạy 0,667 → 0,707

F1 0,676 → 0,697

gần như không tổn độ đặc hiệu.

Ngưỡng 0,33

Ưu tiên lâm sàng

Bắt được 85% số ca AKI

Độ nhạy 0,853

đổi lại độ đặc hiệu giảm còn 0,555.



Kết luận then chốt


**Ngưỡng là đòn bẩy
cải thiện độ nhạy
lâm sàng mạnh hơn
cả tinh chỉnh siêu**

KẾT QUẢ VÀ ĐÁNH GIÁ

So sánh với các kết quả liên quan

Phương pháp	AUC (val)	Ghi chú
Random Forest (baseline)	0,806	min/mean/max · balanced · chưa tinh chỉnh
Random Forest (tinh chỉnh)	0,807	GridSearchCV 1.080 tổ hợp · CV 0,8109
XGBoost — Fan và cs. (2023)	~0,800	LASSO-CV 7 biến · giá trị đo đầu tiên

Kiểm tra quá khớp — Train vs Validation



Độ quan trọng đặc trưng

Nhóm đóng góp lớn nhất: **saps2, oasis, sofa, egfr, age** và thống kê của **bun / weight** — phù hợp với phân tích tương quan EDA và với bài báo gốc.



Còn quá khớp

AUC train $\approx 1,0$ (cây sâu học thuộc lòng huấn luyện) so với validation 0,807. Tinh chỉnh cải thiện khả năng tổng quát nhưng chưa thu hẹp khoảng cách này — hướng cải tiến cho phiên bản sau.

- **Tiền xử lý chống rò rỉ**
flatten min/mean/max · KNN · mã hoá – chuẩn hoá
- **Tinh chỉnh hệ thống & kiểm chứng được**
GridSearchCV 1.080 tổ hợp → CV ROC-AUC 0,8042 → 0,8109; AUC test 0,807.
- **Ngưỡng là đòn bẩy lâm sàng mạnh nhất**
Độ nhạy lên 0,707 hoặc 0,853 tùy điểm vận hành, hơn cả tinh chỉnh siêu tham số.



Định hướng tương lai

- Lựa chọn đặc trưng bằng LASSO để giảm 77 chiều & giảm phương sai
- Hiệu chỉnh xác suất (CalibratedClassifierCV) cho quyết định lâm sàng
- Kiểm định chéo lồng (nested CV) để ước lượng không thiên lệch
- Xem lại chính sách gộp trùng (chọn lần ICU nguy cơ cao nhất)