

DỰ ĐOÁN TỔN THƯƠNG THẬN CẤP Ở BỆNH NHÂN NHIỄM TOAN CETON DO ĐÁI THÁO ĐƯỜNG (DKA-AKI) SỬ DỤNG MÔ HÌNH RANDOM FOREST

Sinh viên thực hiện: Đỗ Thành Đạt – 20261103M

Tóm tắt (Abstract)

Tổn thương thận cấp (Acute Kidney Injury – AKI) là một biến chứng nặng và thường gặp ở bệnh nhân nhiễm toan ceton do đái tháo đường (Diabetic Ketoacidosis – DKA), làm tăng tỉ lệ tử vong và kéo dài thời gian nằm viện. Việc phát hiện sớm nguy cơ AKI ngay từ khi bệnh nhân nhập đơn vị hồi sức tích cực (ICU) có ý nghĩa lâm sàng quan trọng nhằm hỗ trợ bác sĩ can thiệp kịp thời.

Trong báo cáo này, em thực hiện xây dựng một hệ thống học máy dự đoán bệnh nhân DKA có phát triển AKI trong vòng một tuần kể từ khi nhập ICU hay không – một bài toán phân loại nhị phân – trên dữ liệu trích xuất từ MIMIC-IV theo nghiên cứu của Fan và cộng sự năm 2023. Đóng góp trọng tâm của báo cáo nằm ở quy trình xử lý dữ liệu và xây dựng – tinh chỉnh mô hình. Về dữ liệu, mỗi bệnh nhân được mô tả bằng các đặc trưng tĩnh và các đặc trưng động dạng chuỗi thời gian; em đề xuất làm phẳng mỗi chuỗi động thành ba thống kê min/mean/max thay vì chỉ lấy một giá trị như bài báo gốc, qua đó giữ lại tín hiệu cực trị mang ý nghĩa lâm sàng. Quy trình bao gồm điền khuyết bằng KNNImputer, mã hoá biến phân loại và chuẩn hoá, toàn bộ được lưu lại và chỉ áp dụng trên tập kiểm thử nhằm chống rò rỉ dữ liệu. Về mô hình, em sử dụng Random Forest với cơ chế cân bằng lớp (`class_weight='balanced'`) cho dữ liệu mất cân bằng (38,9% dương tính), sau đó tinh chỉnh siêu tham số một cách hệ thống bằng GridSearchCV trên 1.080 tổ hợp với kiểm định chéo phân tầng 5-fold, chọn theo độ đo ROC-AUC.

Kết quả của hệ thống qua quá trình thử nghiệm thu được như sau: ROC-AUC kiểm định chéo tăng từ 0,8042 lên 0,8109, trên tập kiểm thử nội bộ mô hình đạt AUC 0,807. Việc tinh chỉnh ngưỡng quyết định nâng độ nhạy từ 0,667 lên 0,707 (ngưỡng 0,47) hoặc 0,853 (ngưỡng 0,33) tùy ưu tiên lâm sàng.

Các đóng góp chính của báo cáo (Highlight)

Xây dựng một quy trình tiền xử lý dữ liệu Test hoàn chỉnh, tái sử dụng được và chống rò rỉ dữ liệu cho tập dữ liệu DKA-AKI từ MIMIC-IV:

- Làm phẳng bản ghi ICU với min/mean/max cho các giá trị đặc trưng động
- Điền khuyết KNN
- Mã hóa - chuẩn hóa lại các trường dữ liệu

So sánh và đề xuất phương pháp xử lý dữ liệu đặc trưng động – Sử dụng thêm giá trị lớn nhất và nhỏ nhất thay vì chỉ giá trị trung bình thay cho giá trị động.

Tinh chỉnh siêu tham số cho mô hình Random Forest một cách hệ thống và kiểm chứng rõ ràng

Tinh chỉnh ngưỡng quyết định theo ưu tiên lâm sàng, cung cấp hai điểm vận hành:

Từ khóa (Keywords)

Tổn thương thận cấp (Acute Kidney Injury); Nhiễm toan ceton đái tháo đường (Diabetic Ketoacidosis); Random Forest; Tinh chỉnh siêu tham số (Hyperparameter Tuning); Học máy (Machine Learning); MIMIC-IV; Dữ liệu mất cân bằng (Imbalanced Data); Tinh chỉnh ngưỡng quyết định (Decision Threshold Tuning)

I. Giới thiệu (Introduction)

Học máy (Machine Learning) ngày càng đóng vai trò quan trọng trong y học, đặc biệt trong các mô hình dự đoán lâm sàng nhằm hỗ trợ chẩn đoán, tiên lượng và ra quyết định điều trị. Với sự phổ biến của hồ sơ sức khỏe điện tử (Electronic Health Records – EHR) và các kho dữ liệu hồi sức mở như MIMIC-IV (Johnson và cộng sự, 2023), việc khai thác dữ liệu lâm sàng quy mô lớn để dự báo các biến cố nguy hiểm đã trở thành một hướng nghiên cứu sôi động. Các mô hình như vậy có thể cảnh báo sớm cho bác sĩ, giúp phân tầng nguy cơ và phân bổ nguồn lực chăm sóc hợp lý hơn.

Nhiễm toan ceton do đái tháo đường (DKA) là một cấp cứu nội tiết – chuyển hoá thường gặp, đặc biệt ở bệnh nhân đái tháo đường type 1 và một bộ phận đái tháo đường type 2. Một trong những biến chứng nguy hiểm của DKA là tổn thương thận cấp (AKI) — tình trạng suy giảm chức năng thận đột ngột, được định nghĩa theo tiêu chuẩn KDIGO (Khwaja, 2012) dựa trên mức tăng creatinine huyết thanh và/hoặc giảm lượng nước tiểu. AKI làm tăng đáng kể tỉ lệ tử vong, nguy cơ tiến triển thành bệnh thận mạn và chi phí điều trị. Do đó, dự đoán sớm nguy cơ AKI ở bệnh nhân DKA ngay tại thời điểm nhập ICU là một bài toán có giá trị lâm sàng rõ ràng.

Bài toán báo cáo này muốn giải quyết như sau: Cho thông tin của một bệnh nhân DKA trong 24 giờ đầu nằm ICU (gồm nhân khẩu học, các bệnh nền, điểm độ nặng và các chuỗi sinh hiệu, xét nghiệm), hãy dự đoán bệnh nhân có phát triển AKI trong vòng một tuần hay không. Đây là bài toán phân loại nhị phân với nhãn `akdPositive`. Thách thức của bài toán nằm ở ba điểm:

- Dữ liệu mất cân bằng (chỉ 38,9% ca dương tính), khiến độ chính xác (accuracy) trở nên kém tin cậy
- Các đặc trưng động là chuỗi thời gian có độ dài thay đổi, cần được tổng hợp về một biểu diễn cố định mà không đánh mất tín hiệu
- Nguy cơ quá khớp (overfitting) trên một tập dữ liệu tương đối nhỏ (970 mẫu)

Các nghiên cứu trước đây thường tiếp cận bài toán dự đoán AKI bằng hồi quy logistic truyền thống (Hosmer & Lemeshow) hoặc các mô hình học máy đơn lẻ. Gần đây, các mô hình dựa trên cây quyết định, đặc biệt là các phương pháp học tập hợp (ensemble) như Random Forest (Breiman, 2001) và cây tăng cường gradient như XGBoost (Chen & Guestrin, 2016), cho thấy hiệu năng vượt trội nhờ khả năng nắm bắt quan hệ phi tuyến và tương tác giữa các đặc trưng. Bài báo nền tảng

của dự án — Fan và cộng sự (2023) — so sánh tám mô hình học máy và kết luận XGBoost cho kết quả tốt nhất ($AUC \approx 0,80$), sử dụng lựa chọn đặc trưng bằng LASSO và chỉ giữ giá trị đo đầu tiên của mỗi chuỗi động.

Trong báo cáo này, em tập trung vào quy trình xử lý dữ liệu và quá trình xây dựng – tinh chỉnh mô hình Random Forest, vốn là một mô hình nền (baseline) mạnh, ổn định và dễ diễn giải. Em cải tiến khâu biểu diễn đặc trưng (min/mean/max thay vì một giá trị đơn) để giữ lại tín hiệu cực trị, thiết lập một pipeline tái lập được và chống rò rỉ dữ liệu, rồi tinh chỉnh siêu tham số một cách hệ thống bằng GridSearchCV với kiểm định chéo phân tầng. Khác với mô hình nền chưa tinh chỉnh ở phiên bản đầu, phiên bản này khảo sát toàn diện không gian siêu tham số, ghi lại mọi cấu hình đã thử và phân tích ảnh hưởng của ngưỡng quyết định tới các độ đo lâm sàng. Mục tiêu không phải là tạo ra một bước nhảy vọt về AUC — điều khó xảy ra với một mô hình vốn đã mạnh như Random Forest — mà là chứng minh một quy trình thực nghiệm chặt chẽ, minh bạch và có thể kiểm chứng, đồng thời làm rõ đâu là đòn bẩy thực sự cải thiện kết quả lâm sàng (ở đây là ngưỡng quyết định). Phần còn lại của báo cáo được tổ chức như sau: Mục II trình bày các nghiên cứu liên quan; Mục III mô tả tập dữ liệu, kiến trúc mô hình đề xuất và các độ đo; Mục IV trình bày thử nghiệm, kết quả tinh chỉnh và đánh giá; Mục V kết luận và nêu định hướng tương lai.

II. Các nghiên cứu liên quan (Related Works)

Bài báo nền tảng của dự án là Fan và cộng sự (2023), “Predicting the risk factors of diabetic ketoacidosis-associated acute kidney injury: A machine learning approach using XGBoost”, đăng trên *Frontiers in Public Health*. Nhóm tác giả trích xuất dữ liệu bệnh nhân DKA từ MIMIC-IV, sử dụng lựa chọn đặc trưng bằng LASSO để rút gọn còn bảy biến quan trọng, rồi so sánh tám mô hình học máy (gồm hồi quy logistic, SVM, Random Forest, XGBoost, ...). XGBoost cho AUC cao nhất ($\approx 0,80$) và các đặc trưng quan trọng nhất gồm BUN, lượng nước tiểu, cân nặng, tuổi và số lượng tiểu cầu. Điểm mạnh của nghiên cứu là quy trình chặt chẽ và khả năng diễn giải qua phân tích SHAP; tuy nhiên việc chỉ giữ một giá trị đo đầu tiên của mỗi chuỗi động có thể bỏ phí phần lớn thông tin diễn tiến trong 24 giờ đầu — đây chính là điểm em sẽ tập trung cải tiến.

Về mô hình, công trình này nằm trong dòng nghiên cứu về các phương pháp học tập hợp (ensemble learning). Random Forest (Breiman, 2001) phát triển từ ý tưởng bagging (Breiman, 1996): huấn luyện nhiều cây quyết định trên các mẫu bootstrap khác nhau và, tại mỗi nút, chỉ xét một tập con đặc trưng ngẫu nhiên. Cơ chế kép này khử tương quan (de-correlate) giữa các cây, nhờ đó trung bình hoá dự đoán làm giảm phương sai mà không tăng đáng kể độ chệch — một biểu hiện của đánh đổi bias–variance. Điểm mạnh của Random Forest là ổn định, ít nhạy với siêu tham số, xử lý tốt đặc trưng phi tuyến và tương tác, cung cấp độ quan trọng đặc trưng (feature importance) hữu ích cho diễn giải; điểm yếu là kích thước mô hình lớn và có xu hướng quá khớp khi cây không bị giới hạn độ sâu trên dữ liệu nhỏ.

Về xử lý dữ liệu thiếu, các phương pháp điền khuyết đa biến như KNNImputer (dựa trên ý tưởng của Troyanskaya và cộng sự, 2001 trong điền khuyết dữ liệu sinh học) ước lượng giá trị thiếu từ các mẫu lân cận theo khoảng cách, giữ được cấu trúc tương quan giữa các biến tốt hơn so với điền khuyết bằng trung bình. Các kỹ thuật phức tạp hơn như MissForest (Stekhoven & Bühlmann, 2012) sử dụng chính Random Forest để điền khuyết. Trên dữ liệu của em, mức thiếu

của các biến đo thực sự đều thấp (tối đa $\approx 5,9\%$), nên KNNImputer với $k = 5$ là lựa chọn đủ tốt và đơn giản.

Về mất cân bằng lớp, có hai hướng phổ biến: lấy mẫu lại (resampling) như SMOTE (Chawla và cộng sự, 2002) tạo mẫu thiếu số tổng hợp, hoặc điều chỉnh trọng số lớp (cost-sensitive learning) bằng cách phạt nặng hơn các lỗi trên lớp thiếu số. Vì mức mất cân bằng ở đây là vừa phải (38,9% dương tính), em chọn `class_weight='balanced'` của scikit-learn — gán trọng số tỉ lệ nghịch với tần suất lớp — vốn ít rủi ro rò rỉ và nhiều hơn so với việc sinh mẫu nhân tạo trên dữ liệu lâm sàng nhỏ.

Về tinh chỉnh siêu tham số, GridSearchCV duyệt vét cạn toàn bộ không gian tham số kết hợp với kiểm định chéo. Phát hiện này định hướng không gian tìm kiếm của em và phù hợp với kết quả thực nghiệm (xem Mục IV). Việc lựa chọn mô hình dựa trên ROC-AUC — thay vì accuracy — được củng cố bởi các phân tích của Bradley (1997) và Hanley & McNeil (1982) về tính độc lập với ngưỡng và phù hợp với dữ liệu mất cân bằng của AUC.

Về độ đo và ngưỡng quyết định trong y học, chỉ số Youden (Youden, 1950) là một tiêu chí phổ biến để chọn ngưỡng tối ưu cân bằng độ nhạy và độ đặc hiệu. Trong các ứng dụng cảnh báo AKI, độ nhạy thường được ưu tiên vì bỏ sót ca bệnh (âm tính giả) nguy hiểm hơn báo động giả. Mặt khác, Christodoulou và cộng sự (2019) lưu ý rằng trong nhiều bài toán dự báo lâm sàng, học máy phức tạp không nhất thiết vượt trội so với hồi quy logistic, củng cố giá trị của một mô hình nền mạnh và minh bạch như Random Forest.

Cuối cùng, các điểm độ nặng được dùng làm đặc trưng — SOFA (Vincent và cộng sự, 1996), SAPS II (Le Gall và cộng sự, 1993) và OASIS — là những thang điểm đã được kiểm chứng rộng rãi trong hồi sức, và dữ liệu của em cho thấy chúng nằm trong nhóm tương quan mạnh nhất với AKI.

Tổng hợp lại, các nghiên cứu trên định hình ba lựa chọn cốt lõi của báo cáo: (i) biểu diễn đặc trưng động bằng min/mean/max để giữ tín hiệu cực trị; (ii) Random Forest có cân bằng lớp làm mô hình nền, tinh chỉnh bằng GridSearchCV với ROC-AUC; và (iii) tinh chỉnh ngưỡng quyết định theo ưu tiên độ nhạy lâm sàng.

III. Mô hình đề xuất (Proposal Model)

Mục tiêu: dự đoán bệnh nhân nhiễm toan ceton do đái tháo đường (DKA) có phát triển tổn thương thận cấp (AKI) trong vòng một tuần kể từ khi nhập ICU hay không — bài toán phân loại nhị phân với nhãn `akdPositive`.

III.1. Tập dữ liệu

Dữ liệu được trích xuất từ MIMIC-IV (Johnson và cộng sự, 2023) theo nghiên cứu Fan và cộng sự (2023); mỗi bản ghi tương ứng với một lần nằm ICU của một bệnh nhân DKA, lưu ở định dạng JSON. Nhãn `akdPositive` (kiểu boolean) cho biết bệnh nhân có phát triển AKI hay không, theo tiêu chuẩn KDIGO.

Tập	Số bản ghi	Có nhãn?	Tỷ lệ dương tính
-----	------------	----------	------------------

train.json	970	Có (akdPositive)	377/970 = 38,9%
test.json	243	Không	Không có thông tin

Mỗi bệnh nhân có 37 trường dữ liệu đo lường thông tin (measures), chia làm hai nhóm:

- Đặc trưng tĩnh (20 trường): mỗi trường một giá trị – nhân khẩu học (age, gender, race), loại đái tháo đường (dka_type), mức độ bệnh gan (liver_disease), các điểm độ nặng (oasis, saps2, sofa), thời gian trước ICU (preiculus), mức lọc cầu thận (egfr) và các cở bệnh nền (tăng huyết áp, suy tim, ung thư, biến chứng mạch máu, giai đoạn CKD, ...)
- Đặc trưng động (17 trường): Các số đo trong khoảng thời gian 24 giờ đầu ICU – sinh hiệu (hr, rr, sbp, dbp, gcs) – được lấy mẫu hàng chục đến hàng trăm lần, và các xét nghiệm (ag, bg, bicarbonate, bun, scr, phosphate, calcium, weight, plt, hb, wbc) lấy mẫu vài lần. Mỗi chuỗi là một ảnh xạ { thời điểm : giá trị }


Về phân chia dữ liệu, do test.json không có nhãn nên không thể dùng để đánh giá, em quyết định tách 20% tập dữ liệu huấn luyện làm tập kiểm thử nội bộ (validation) – giữ nguyên tỉ lệ dương tính ~38,9%; 80% còn lại sẽ sử dụng để huấn luyện và tinh chỉnh mô hình. Sau khi chọn được cấu hình tốt nhất, mô hình được huấn luyện lại trên toàn bộ 970 mẫu trước khi được sử dụng cho dự đoán tập dữ liệu test nằm tận dụng tối đa dữ liệu hiện có.

Tập	Số bệnh nhân	Tỉ lệ dương tính	Mục đích
Huấn luyện (Train)	776	38,9%	Huấn luyện và kiểm định chéo
Kiểm thử nội bộ (Validation)	194	38,7%	Đánh giá hiệu năng
Kiểm thử (Test)	243 (222 sau khi làm sạch)*	Không nhãn	Dự đoán và nộp kết quả
Huấn luyện lại (Refit)	970	38,9%	Huấn luyện mô hình lần cuối trước khi dự đoán


(*) Một bệnh nhân (trường *subjectId*) có thể có nhiều lần nhập viện/nằm ICU; theo yêu cầu bài toán, mỗi *subjectId* chỉ giữ một bản ghi (bản ghi đầu tiên), nên 243 bản ghi sau khi xử lý sẽ rút ngắn còn 222 bệnh nhân khi xuất kết quả.

III.2. Kiến trúc của mô hình đề xuất

Kiến trúc tổng thể của gồm hai mô-đun nối tiếp (A) tiền xử lý dữ liệu và (B) mô hình Forest:




Mô-đun A – Tiền xử lý dữ liệu với đầu vào là file JSON chứa dữ liệu thô, đầu ra là file CSV với dữ liệu đã chuẩn hóa với 77 trường dữ liệu:



- Làm phẳng – mỗi bệnh nhân sẽ được làm phẳng thành một dòng dữ liệu với các đặc trưng tĩnh giữ nguyên, mỗi đặc trưng động được tổng hợp thành 3 thống kê min/mean/max (tổng 51 cột sinh từ 17 trường). Lý do đề xuất cần thêm giá trị lớn/nhỏ nhất là bởi cực trị của các chỉ số lâm sàng như creatinine/BUN, huyết áp có thể báo hiệu nhiều thông tin trong khi trung bình không đem lại những thông tin đó. Ví dụ như chỉ số sbp với 3 thống kê min = -0,26, mean = +0,05 và max = +0,27 – giá trị trung bình che dấu hoàn toàn cảnh báo tín hiệu chỉ số có thể vượt hay nằm dưới ngưỡng cho phép.
- Các thông tin bệnh nền (hypertension, microangiopathy, ...) và ckd_stage chỉ được ghi nhận khi có bệnh, do vậy việc có thể thiếu dữ liệu ở các trường này là hoàn toàn hợp lý chứ không phải do bộ dữ liệu thiếu. Ở đây em chọn điền 0 ở các trường này nếu thiếu dữ liệu.
- Loại đặc trưng mẫu: Theo bài báo ta sẽ loại các đặc trưng bị thiếu lên đến hơn 20% trên toàn bộ tập dữ liệu. Với các đặc trưng khuyết không vượt ngưỡng sẽ được điền với KNNImputer.
- Thông tin mã hóa biến phân loại
 - Gender F/M chuyển về 0/1
 - Thông tin liver disease NONE/MILD/SEVERE chuyển về 0/1/2
 - Thông tin race được nhóm thành các nhóm màu da và dùng onehot để đánh cờ dữ liệu: race_Asian, race_Black, race_Hispanic, race_Other, race_White
 - Dka_type – 3 loại đái tháo đường
- Chuẩn hóa với hàm StandardScaler

Mô-đun B – Mô hình Random Forest với đầu vào là ma trận (970 x 77) và nhãn y đánh dấu tổn thương thận (0/1), đầu ra là xác suất dự đoán AKI cho mỗi bệnh nhân.



- Bagging: Mỗi cây được huấn luyện trên một mẫu bootstrap (lấy có hoàn lại) từ tập huấn luyện, tạo sự đa dạng giữa các cây.
- Feature Subsampling: Tại mỗi nút, chia tập con ngẫu nhiên gồm max_features đặc trưng được xét với hàm log2, từ đó giúp khử tương quan giữa các cây
- Tiêu chí chia nút sử dụng Gini - chọn phép chia làm giảm Gini nhiều nhất. Cấu hình class_weight = 'balanced' để xử lý mất cân bằng
- Đầu ra dự đoán: Xác suất lớp P là trung bình xác suất trên toàn bộ các cây. Nhãn dự đoán = 1 nếu $P \geq$ ngưỡng
- Độ quan trọng của mỗi đặc trưng sẽ được tính từ mức giảm Gini trung bình mà mỗi đặc trưng mang lại trên toàn rừng,

III.3. Các độ đo đánh giá

Gọi TP, TN, FP, FN lần lượt là số dương tính thật, âm tính thật, dương tính giả và âm tính giả. Theo bài báo gốc, mô hình được đánh giá bằng các độ đo sau:

- Accuracy (độ chính xác) = $(TP + TN) / (TP + TN + FP + FN)$: tỉ lệ dự đoán đúng trên toàn bộ mẫu. Kém tin cậy khi dữ liệu mất cân bằng.
- Sensitivity (độ nhạy / recall) = $TP / (TP + FN)$: tỉ lệ ca AKI thực sự được phát hiện đúng - rất quan trọng về lâm sàng vì bỏ sót AKI nguy hiểm hơn báo động giả.

- Specificity (độ đặc hiệu) = $TN / (TN + FP)$: tỉ lệ ca không AKI được nhận đúng.
- F1 (lớp AKI) = $2 \cdot \text{Precision} \cdot \text{Recall} / (\text{Precision} + \text{Recall})$, với $\text{Precision} = TP / (TP + FP)$: trung bình điều hoà giữa độ chính xác dương tính và độ nhạy.
- AUC (diện tích dưới đường cong ROC): khả năng phân biệt hai lớp ở mọi ngưỡng; càng gần 1 càng tốt, 0,5 là ngẫu nhiên. Độc lập với ngưỡng và phù hợp dữ liệu mất cân bằng, nên là độ đo chính để chọn mô hình.

IV. Thử nghiệm và đánh giá (Experiments and Discussions)

IV.1. Thử nghiệm

Môi trường: JupyterLab chạy trong Docker, Python 3.11, các thư viện được ghim phiên bản trong requirements.txt (scikit-learn 1.1.3, numpy 1.26.4, pandas 2.1.4). Mô hình dùng `sklearn.ensemble.RandomForestClassifier`. Vì dữ liệu nhỏ (970×77), huấn luyện một mô hình chỉ mất vài giây trên CPU; toàn bộ tìm kiếm lưới ($1.080 \text{ tổ hợp} \times 5 \text{ fold} = 5.400 \text{ lần khớp}$) mất khoảng 45 phút trên 6 nhân CPU. Mọi kết quả đều tái lập được nhờ `random_state = 42` và bộ chia kiểm định chéo cố định.

Các thử nghiệm được thực hiện: (1) đo mô hình nền (baseline) với cùng quy trình kiểm định chéo dùng cho tìm kiếm, ghi làm thí nghiệm #0; (2) tìm kiếm lưới GridSearchCV trên sáu siêu tham số có ý nghĩa với StratifiedKFold(5) chọn theo ROC-AUC; (3) tinh chỉnh ngưỡng quyết định trên tập validation; (4) phân tích độ quan trọng đặc trưng; (5) huấn luyện lại cấu hình tốt nhất trên toàn bộ 970 mẫu và dự đoán tập test.

Thông tin siêu tham số và giá trị thử (in đậm và các cấu hình chạy bước (1) - baseline)

Siêu tham số	Ý nghĩa	Giá trị thử	Lý do
n_estimators	Số lượng cây	200, 300 , 500, 800	Nhiều cây hơn giúp mô hình ổn định hơn
max_depth	Độ sâu tối đa của mỗi cây	None , 5, 10, 20, 30	Kiểm soát quá khớp chính
min_samples_split	Số mẫu tối thiểu tại một node để có thể thực hiện chia tiếp	2 , 5, 10	Chính quy hóa
min_samples_leaf	Số mẫu tối thiểu mà tại node cuối phải có	1, 2 , 4	Làm mượt, chống quá khớp
max_features	Số đặc trưng được xét ngẫu nhiên mỗi khi chia node	'sqrt' , 'log2', 0.5	Điều khiển mức khử tương quan giữa các cây
bootstrap	Có sử dụng cơ chế lấy có hoàn lại cho mỗi cây hay không	True , False	Bật/Tắt bagging

Tổng cộng 1080 tổ hợp siêu tham số với cấu hình `class_weight='balanced'` được giữ cố định nhằm cô lập ảnh hưởng của các siêu tham số cấu trúc. Mọi tổ hợp và điểm kiểm định chéo tương ứng được lưu lại để tìm ra cấu hình tốt nhất.

IV.2. Đánh giá

Sau 1080 lần thử với kiểm định chéo phân tầng 5-fold (sử dụng độ đo ROC-AUC). Cấu hình tốt nhất chỉ cần thay đổi hai siêu tham số so với baseline.

Cấu hình	CV ROC-AUC	Cải thiện so với baseline
Baseline (n_estimators=300, max_features=sqrt)	0,8042 ± 0,0438	—
Tốt nhất (n_estimators=500, max_features=log2)	0,8109 ± 0,0445	+0,0067

Thông tin cấu hình cuối cùng:

Siêu tham số	Baseline (v1)	Tinh chỉnh (tốt nhất)
n_estimators	300	500
max_features	'sqrt'	'log2'
max_depth	None	None (giữ nguyên)
min_samples_split	2	2 (giữ nguyên)
min_samples_leaf	2	2 (giữ nguyên)
bootstrap	True	True (giữ nguyên)
class_weight	balanced	balanced (cố định)

Kết quả trên tập kiểm thử nội bộ (194 bệnh nhân) ở các ngưỡng quyết định khác nhau

Cấu hình	Ngưỡng	AUC	Accuracy	Sensitivity	Specificity	F1
Baseline	0,50	0,806	0,753	0,667	0,807	0,676
Tinh chỉnh	0,50	0,807	0,758	0,667	0,815	0,680
Tinh chỉnh	0,47 (max-F1)	0,807	0,763	0,707	0,798	0,697
Tinh chỉnh	0,33 (lâm sàng)	0,807	0,670	0,853	0,555	0,667

Ma trận nhầm lẫn của mô hình tinh chỉnh tại ngưỡng 0,50 là $[[TN, FP], [FN, TP]] = [[97, 22], [25, 50]]$: trong 75 ca AKI thực sự, mô hình phát hiện đúng 50 ca và bỏ sót 25 ca. Độ nhạy 0,667 cho thấy vẫn bỏ sót khoảng một phần ba số ca AKI ở ngưỡng 0,5 — đây là động lực cho việc tinh chỉnh ngưỡng.

Phân tích ngưỡng quyết định: ROC-AUC không đổi theo ngưỡng, nhưng nhãn 0/1 thì có. Vì bỏ sót một ca AKI (âm tính giả) nguy hại hơn một báo động giả (dương tính giả), em đề xuất hai điểm vận hành: (i) ngưỡng 0,47 tối đa F1 — nâng độ nhạy 0,667 → 0,707 và F1 0,676 → 0,697 gần như không tổn độ đặc hiệu; (ii) ngưỡng 0,33 ưu tiên lâm sàng — bắt được 85% số ca AKI, đổi lại độ đặc hiệu giảm còn 0,555. Đáng chú ý, đòn bẩy ngưỡng tác động tới các độ đo lâm sàng mạnh hơn cả việc tinh chỉnh siêu tham số — một kết luận quan trọng của báo cáo.

Kiểm tra quá khớp — hiệu năng Train so với Validation của mô hình tinh chỉnh:

Độ đo	Train	Validation
AUC	1,000	0,807
Accuracy	0,997	0,758
Sensitivity	1,000	0,667
Specificity	0,996	0,815
F1	0,997	0,680

Điểm số train gần như tuyệt đối ($AUC \approx 1,0$) là bình thường với Random Forest không giới hạn độ sâu (cây sâu học thuộc các dòng huấn luyện). Khoảng cách lớn train – validation cho thấy mô hình còn quá khớp; tinh chỉnh giúp cải thiện khả năng tổng quát (CV AUC $\uparrow$) nhưng chưa thu hẹp khoảng cách này — đây là hướng cải tiến cho các phiên bản sau (lựa chọn đặc trưng, hiệu chỉnh xác suất).

Độ quan trọng đặc trưng: nhóm đóng góp lớn nhất tập trung ở các điểm độ nặng (saps2, oasis, sofa), egfr, age và các thống kê của bun/weight — phù hợp với phân tích tương quan ở bước EDA (saps2 $\approx 0,42$; oasis $\approx 0,42$; egfr $\approx -0,42$; sofa $\approx 0,39$; age $\approx 0,37$) và với nhóm đặc trưng quan trọng trong bài báo gốc (BUN, cân nặng, tuổi), xác nhận mô hình dựa trên tín hiệu lâm sàng hợp lý.

Suy luận trên tập test: 243 bản ghi được tiền xử lý thành ma trận 243×77 (khớp đúng thứ tự cột huấn luyện, không còn giá trị khuyết). Sau khi gộp theo subjectId còn 222 bệnh nhân, trong đó ~ 94 ca (42,3%) được dự đoán là AKI ở ngưỡng chuẩn 0,5 — gần với tỉ lệ $\sim 39\%$ của tập huấn luyện, một kiểm tra hợp lý cho thấy phân phối dự đoán đáng tin. File kết quả test_predictions_randomforest.csv gồm các cột định danh, xác suất và nhãn dự đoán. Các ngưỡng thay thế (0,47; 0,33) được ghi lại nhưng không áp vào file nộp để tôn trọng quy ước ngưỡng 0,5 ban đầu.

So sánh với các kết quả liên quan:

Phương pháp	AUC (validation)	Ghi chú
Random Forest (baseline)	0,806	80/20, min/mean/max, class_weight balanced, chưa tinh chỉnh
Random Forest (tinh chỉnh)	0,807	80/20, GridSearchCV 1.080 tổ hợp, CV ROC-AUC 0,8109

Nhận xét: Random Forest tinh chỉnh đạt AUC tương đương mô hình tốt nhất của bài báo gốc dù dùng biểu diễn đặc trưng và cách chia dữ liệu khác. Mức tăng AUC từ tinh chỉnh siêu tham số là nhỏ và nằm trong sai số CV — đúng với bản chất “mạnh sẵn” của Random Forest — trong khi tinh chỉnh ngưỡng mới là đòn bẩy cải thiện độ nhạy lâm sàng đáng kể

IV.3. Các đóng góp chính của bài báo

Quy trình tiền xử lý tái sử dụng được với biểu diễn đặc trưng động bằng min/mean/max, có bằng chứng định lượng (tương quan sbp: min $-0,26$ / mean $+0,05$ / max $+0,27$) cho thấy giữ lại được tín hiệu cực trị mà cách lấy một giá trị đơn làm mất.

Tinh chỉnh siêu tham số Random Forest đầy đủ và kiểm chứng được: 1.080 tổ hợp với kiểm định chéo phân tầng, nâng CV ROC-AUC $0,8042 \rightarrow 0,8109$, và nhật ký thử nghiệm ghi lại mọi cấu hình (rf_experiment_log, rf_grid_search_all) bảo đảm tính minh bạch.

Tinh chỉnh ngưỡng quyết định theo ưu tiên lâm sàng với hai điểm vận hành ($0,47$ và $0,33$), cho thấy ngưỡng là đòn bẩy mạnh hơn siêu tham số đối với độ nhạy.

V. Kết luận (Conclusions and Perspectives)

Báo cáo đã trình bày một quy trình hoàn chỉnh cho bài toán dự đoán tổn thương thận cấp ở bệnh nhân nhiễm toan ceton do đái tháo đường (DKA-AKI) trên dữ liệu MIMIC-IV, với trọng tâm là khâu xử lý dữ liệu và xây dựng – tinh chỉnh mô hình Random Forest. Quy trình tiền xử lý làm phẳng bản ghi bằng min/mean/max, điền khuyết KNN, mã hoá – chuẩn hoá và chống rò rỉ dữ liệu; mô hình Random Forest có cân bằng lớp được tinh chỉnh hệ thống bằng GridSearchCV trên 1.080 tổ hợp với kiểm định chéo phân tầng theo ROC-AUC. Mô hình đạt CV ROC-AUC $0,8109$ và AUC $0,807$ trên tập kiểm thử nội bộ — tương đương kết quả công bố của bài báo gốc — và việc tinh chỉnh ngưỡng quyết định nâng độ nhạy lâm sàng lên $0,707$ hoặc $0,853$ tùy điểm vận hành. Một kết luận đáng chú ý là, với một mô hình vốn mạnh như Random Forest, ngưỡng quyết định là đòn bẩy cải thiện kết quả lâm sàng mạnh hơn so với tinh chỉnh siêu tham số.

Hạn chế hiện tại: mô hình vẫn còn quá khớp (AUC train $\approx 1,0$ so với validation $0,807$); chỉ dùng một lần tách validation thay vì kiểm định chéo cho ước lượng cuối; chính sách gộp trùng theo bản ghi đầu tiên còn võ đoán; và biểu diễn đặc trưng khác bài báo nên không phải tái hiện 1:1. Định hướng tương lai:

- Lựa chọn đặc trưng bằng LASSO (như bài báo gốc) để giảm số chiều từ 77 đặc trưng và có thể giảm phương sai.
- So sánh với XGBoost tinh chỉnh trên cùng các fold và độ đo để đánh giá công bằng giữa các mô hình.
- Hiệu chỉnh xác suất (CalibratedClassifierCV) nếu xác suất dự đoán được dùng cho quy tắc quyết định lâm sàng.
- Dùng kiểm định chéo lồng (nested CV) để ước lượng không thiên lệch hiệu năng của chính quy trình tinh chỉnh.
- Xem lại chính sách gộp trùng (chọn lần nằm ICU có nguy cơ cao nhất thay vì lần đầu tiên).

Tài liệu tham khảo (References)

- [1] Fan, Z., Jiang, J., Xie, C., Hua, Z., & ... (2023). Predicting the risk factors of diabetic ketoacidosis-associated acute kidney injury: A machine learning approach using XGBoost. *Frontiers in Public Health*, 11, 1087297.
- [2] Khwaja, A. (2012). KDIGO clinical practice guidelines for acute kidney injury. *Nephron Clinical Practice*, 120(4), c179–c184.
- [3] Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32.
- [4] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, 785–794.
- [5] Breiman, L. (1996). Bagging predictors. *Machine Learning*, 24(2), 123–140.
- [6] Troyanskaya, O., Cantor, M., Sherlock, G., et al. (2001). Missing value estimation methods for DNA microarrays. *Bioinformatics*, 17(6), 520–525.
- [7] Stekhoven, D. J., & Bühlmann, P. (2012). MissForest—non-parametric missing value imputation for mixed-type data. *Bioinformatics*, 28(1), 112–118.
- [8] Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, 16, 321–357.
- [9] Bradley, A. P. (1997). The use of the area under the ROC curve in the evaluation of machine learning algorithms. *Pattern Recognition*, 30(7), 1145–1159.
- [10] Hanley, J. A., & McNeil, B. J. (1982). The meaning and use of the area under a receiver operating characteristic (ROC) curve. *Radiology*, 143(1), 29–36.
- [11] Christodoulou, E., Ma, J., Collins, G. S., et al. (2019). A systematic review shows no performance benefit of machine learning over logistic regression for clinical prediction models. *Journal of Clinical Epidemiology*, 110, 12–22.
- [12] Vincent, J. L., Moreno, R., Takala, J., et al. (1996). The SOFA (Sepsis-related Organ Failure Assessment) score to describe organ dysfunction/failure. *Intensive Care Medicine*, 22(7), 707–710.
- [13] Le Gall, J. R., Lemeshow, S., & Saulnier, F. (1993). A new Simplified Acute Physiology Score (SAPS II) based on a European/North American multicenter study. *JAMA*, 270(24), 2957–2963.