

BÁO CÁO PROJECT LẦN 1 – DỰ ĐOÁN TỔN THƯƠNG THẬN CẤP (DKA-AKI) BẰNG MÔ HÌNH RANDOM FOREST

III. Mô hình đề xuất (Proposal Model)

Mục tiêu: dự đoán bệnh nhân nhiễm toan ceton do đái tháo đường (DKA) có phát triển tổn thương thận cấp (AKI) trong vòng một tuần kể từ khi nhập ICU hay không — bài toán phân loại nhị phân với nhãn akdPositive.

III.1. Tập dữ liệu

Dữ liệu được trích xuất từ MIMIC-IV – mỗi bản ghi tương ứng với một lần nằm ICU của một bệnh nhân DKA. Nhãn akdPositive cho biết bệnh nhân có phát triển AKI hay không.

Tập	Số bản ghi	Có nhãn?	Tỉ lệ dương tính
train.json	970	Có (akdPositive)	$377/970 = 38,9\%$
test.json	243	Không	—

Mỗi bệnh nhân có 37 trường đo (measures), chia hai nhóm:

- Đặc trưng tĩnh (20 trường): mỗi trường một giá trị — nhân khẩu học (age, gender, race), loại đái tháo đường (dka_type), mức độ bệnh gan (liver_disease), các điểm độ nặng (oasis, saps2, sofa), thời gian trước ICU (preiculos), mức lọc cầu thận (egfr) và các cở bệnh nền.
- Đặc trưng động (17 trường): chuỗi thời gian trong 24 giờ đầu ICU — sinh hiệu (hr, rr, sbp, dbp, gcs) và xét nghiệm (ag, bg, bicarbonate, bun, scr, phosphate, calcium, weight, plt, hb, wbc).


Phân chia dữ liệu: tách 20% dữ liệu huấn luyện làm tập kiểm thử nội bộ (validation); 80% còn lại để huấn luyện. Sau khi đánh giá, mô hình được huấn luyện lại trên toàn bộ 970 mẫu trước khi dự đoán test.

Tập	Số bệnh nhân	Tỉ lệ dương tính	Mục đích
Huấn luyện (Train)	776	38,9%	Huấn luyện mô hình
Kiểm thử nội bộ (Validation)	194	38,7%	Đánh giá hiệu năng
Kiểm thử (Test)	243 → 222*	không nhãn	Dự đoán & nộp kết quả

(*) Một bệnh nhân (subjectId) có thể có nhiều lần nằm ICU; theo yêu cầu, mỗi subjectId chỉ giữ một bản ghi (bản ghi đầu tiên), nên 243 bản ghi rút còn 222 bệnh nhân khi xuất kết quả.

III.2. Kiến trúc của mô hình đề xuất

Kiến trúc gồm hai mô-đun nối tiếp: (A) tiền xử lý dữ liệu và (B) mô hình Random Forest. Sơ đồ luồng dữ liệu tổng quát:



Mô-đun A — Tiền xử lý. Đầu vào: bản ghi JSON thô; đầu ra: ma trận đặc trưng số đã chuẩn hoá (970×77) cùng bộ biến đổi `preprocessor.joblib`. Các bước:

- Làm phẳng (flatten) — mỗi bệnh nhân thành một dòng: đặc trưng tĩnh giữ nguyên; mỗi đặc trưng động được tổng hợp thành ba thống kê min/mean/max ($17 \times 3 = 51$ cột).
- Cờ bệnh nền vắng mặt được điền 0 (chỉ ghi nhận khi có bệnh — khuyết cấu trúc, không phải dữ liệu thiếu).
- Loại đặc trưng khuyết $> 20\%$ (theo bài báo); dữ liệu này không có đặc trưng đo nào vượt ngưỡng (tối đa $\approx 5,9\%$). Điền các giá trị số còn thiếu bằng `KNNImputer` ($k = 5$).
- Mã hoá biến phân loại: gender F/M $\rightarrow$ 0/1; liver_disease NONE/MILD/SEVERE $\rightarrow$ 0/1/2 (thứ tự); race gộp 23 nhân thành 5 nhóm rồi one-hot; dka_type (T1DM/T2DM/Other) one-hot. Chuẩn hoá các cột số bằng `StandardScaler`.
- Bộ imputer + scaler + danh sách cột được lưu vào `preprocessor.joblib` và chỉ được transform (không fit lại) trên tập test để chống rò rỉ dữ liệu (data leakage).

Mô-đun B — Random Forest. Đầu vào: ma trận X (970×77) và nhãn y ; đầu ra: xác suất dự đoán AKI cho mỗi bệnh nhân. Random Forest là mô hình học tập hợp gồm nhiều cây quyết định huấn luyện trên các mẫu bootstrap và tập con đặc trưng ngẫu nhiên, rồi lấy trung bình xác suất — giảm quá khớp so với một cây đơn lẻ. Cấu hình: `n_estimators = 300`; `max_depth` không giới hạn; `min_samples_leaf = 2`; `class_weight = 'balanced'` (bù mất cân bằng lớp 38,9% dương tính); `random_state = 42` để tái lập.

III.3. Các độ đo đánh giá

Gọi TP, TN, FP, FN lần lượt là số dương tính thật, âm tính thật, dương tính giả và âm tính giả.

- Accuracy (độ chính xác) = $(TP + TN) / (TP + TN + FP + FN)$: tỉ lệ dự đoán đúng trên toàn bộ mẫu.
- Sensitivity (độ nhạy / recall) = $TP / (TP + FN)$: tỉ lệ ca AKI thực sự được phát hiện đúng — rất quan trọng về lâm sàng vì bỏ sót AKI nguy hiểm hơn báo động giả.
- Specificity (độ đặc hiệu) = $TN / (TN + FP)$: tỉ lệ ca không AKI được nhận đúng.
- F1 (lớp AKI) = $2 \cdot \text{Precision} \cdot \text{Recall} / (\text{Precision} + \text{Recall})$, với $\text{Precision} = TP / (TP + FP)$.
- AUC: diện tích dưới đường cong ROC — khả năng phân biệt hai lớp ở mọi ngưỡng; càng gần 1 càng tốt, 0,5 là ngẫu nhiên. Đây là độ đo chính để chọn mô hình.

IV. Thử nghiệm và đánh giá (Experiments and Discussions)

IV.1. Thử nghiệm

Môi trường: JupyterLab chạy trong Docker, Python 3.11, các thư viện được ghim phiên bản trong requirements.txt (scikit-learn 1.1.3, numpy 1.26.4, pandas 2.1.4). Mô hình dùng `sklearn.ensemble.RandomForestClassifier`. Thời gian huấn luyện ở mức vài giây trên CPU do dữ liệu nhỏ (970×77).

Các thử nghiệm: (1) huấn luyện Random Forest trên 776 mẫu, đánh giá trên 194 mẫu validation bằng bộ độ đo ở mục III.3; (2) so sánh hiệu năng train với validation để kiểm tra quá khớp; (3) phân tích độ quan trọng đặc trưng; (4) huấn luyện lại trên toàn bộ 970 mẫu và dự đoán tập test.

IV.2. Đánh giá

Kết quả trên tập kiểm thử nội bộ (194 bệnh nhân), ngưỡng quyết định 0,5:

Độ đo	Giá trị
AUC	0,806
Accuracy	0,753
Sensitivity (AKI)	0,667
Specificity	0,807
F1 (AKI)	0,676

Ma trận nhầm lẫn $[[TN, FP], [FN, TP]] = [[96, 23], [25, 50]]$: trong 75 ca AKI thực sự, mô hình phát hiện đúng 50 và bỏ sót 25. Độ nhạy 0,667 cho thấy còn bỏ sót khoảng một phần ba số ca AKI ở ngưỡng 0,5 — điểm cần cải thiện.


Kiểm tra quá khớp — hiệu năng Train so với Validation:

Độ đo	Train	Validation
AUC	1,000	0,806
Accuracy	0,997	0,753
Sensitivity	1,000	0,667

Specificity	0,996	0,807
F1	0,997	0,676

Điểm số train gần như tuyệt đối ($AUC \approx 1,0$) là bình thường với Random Forest không giới hạn độ sâu; khoảng cách lớn train – validation cho thấy mô hình còn quá khớp.

Độ quan trọng đặc trưng (feature_importances_): nhóm đóng góp lớn nhất tập trung ở các điểm độ nặng (saps2, oasis, sofa), egfr, age và các thống kê của bun/weight — phù hợp với phân tích tương quan ở bước EDA ($saps2 \approx 0,42$; $oasis \approx 0,42$; $egfr \approx -0,42$; $sofa \approx 0,39$; $age \approx 0,37$) và với nhóm đặc trưng quan trọng của bài báo gốc (BUN, cân nặng, tuổi).



Suy luận trên tập test: 243 bản ghi được tiền xử lý thành ma trận 243×77 (khớp đúng cột huấn luyện, không còn giá trị khuyết). Sau khi gộp theo subjectId, kết quả còn 222 bệnh nhân, trong đó 89 ca (40,1%) được dự đoán là AKI — gần với tỉ lệ $\sim 39\%$ của tập huấn luyện. File kết quả gồm đúng 3 cột: id, probability, prediction.

Bảng so sánh với kết quả liên quan:

Phương pháp	AUC (validation)	Ghi chú
-------------	------------------	---------

Random Forest (v1 — đề xuất)	0,806	80/20, min/mean/max, class_weight='balanced'
XGBoost — Fan và cộng sự (2023)	0,800	85/15, LASSO-CV 7 biến, giá trị đầu tiên

IV.3. Các đóng góp chính của báo cáo

- Quy trình tiền xử lý tái sử dụng được với biểu diễn đặc trưng động bằng min / mean / max, giữ lại tín hiệu cực trị có ý nghĩa lâm sàng.
- Mô hình nền Random Forest đạt AUC 0,806 trên tập kiểm thử nội bộ, tương đương bài báo gốc ($\approx 0,800$), làm mốc so sánh cho các phiên bản sau.
- Cơ chế chống rò rỉ dữ liệu (lưu và chỉ transform bộ tiền xử lý) bảo đảm so sánh công bằng giữa các mô hình.

V. Kết luận (Conclusions and Perspectives)

Báo cáo trình bày tiến độ hiện tại của dự án: một quy trình tiền xử lý hoàn chỉnh và mô hình nền Random Forest cho bài toán dự đoán DKA-AKI trên dữ liệu MIMIC-IV, đạt AUC 0,806 trên tập kiểm thử nội bộ — tương đương kết quả công bố của bài báo gốc.

Định hướng tiếp theo:

- Giảm quá khớp bằng tinh chỉnh siêu tham số (max_depth, min_samples_leaf, max_features) với kiểm định chéo phân tầng (GridSearchCV)
- Tăng độ nhạy bằng cách tinh chỉnh ngưỡng quyết định (vd chỉ số Youden J)
- Thử thêm các mô hình Logistic Regression và XGBoost
- Lựa chọn đặc trưng bằng LASSO như bài báo gốc.